

Mon Super Projet Data Science

Projet Fil Rouge Data Science - Métropole Durable

Étudiant(e) 1 : [Insérer Prénom] Étudiant(e) 2 : [Insérer Prénom] Étudiant(e) 3 : [Insérer Prénom]
Nom] Nom] Nom]

2026-05-18

Table of contents

1	Introduction et Contexte Métier	2
1.1	Contexte du Projet	2
1.2	Objectif Analytique	3
2	Acquisition et Préparation des Données (Data Wrangling)	3
2.1	Audit de Qualité	3
2.2	Algorithme de Nettoyage	3
2.3	Travaux Pratiques de Wrangling	3
3	 Jalon 1 : Data Wrangling & Nettoyage (Squelette Étudiant)	3
3.0.a	1. Importation des packages et chargement des données	3
3.0.b	2. Audit initial des données	3
3.0.c	3. Nettoyage et uniformisation des Dates	4
3.0.d	4. Identification et Traitement des Outliers (Anomalies physiques)	4
3.0.e	5. Imputation des valeurs manquantes	4
3.0.f	6. Sauvegarde des données propres	4
4	Analyse Exploratoire des Données (EDA)	4
4.1	Statistiques Descriptives	4
4.2	Ingénierie de Variables (Feature Engineering)	4
4.3	Travaux Pratiques d'Exploration Visuelle (EDA)	4
5	 Jalon 1 : Analyse Exploratoire des Données (EDA) & Visualisation (Squelette Étudiant) ..	4
5.0.a	1. Importation des packages et configuration du style	5
5.0.b	2. Ingénierie de variables temporelles	5
5.0.c	3. Visualisations Professionnelles	5
5.0.d	4. Synthèse des observations clés	5
6	Visualisation Multidimensionnelle (Insights)	5
6.1	Profils d'Activité Journalière	5
6.2	Corrélations Globales	5
7	Modélisation et Apprentissage	6
7.1	Schéma Global du Pipeline de Données	6
7.2	Modélisation Tabulaire (Prédiction Vélos)	6

7.2.a Travaux Pratiques de Modélisation Tabulaire	6
8 🧠 Jalon 2 : Modélisation Prédictive & Apprentissage (Squelette Étudiant)	6
8.0.a 1. Préparation de l'environnement	7
8.0.b 2. Définition des variables et split chronologique	7
8.0.c 3. Entraînement du modèle de Forêt Aléatoire	7
8.0.d 4. Évaluation métrique	7
8.0.e 5. Importance des variables explicatives	7
8.1 Modélisation Vision (Analyse d'Images)	7
8.1.a Travaux Pratiques de Vision par Ordinateur (CNN)	7
9 📷 Jalon 2 : Brique de Vision par Ordinateur (CNN & TensorFlow) (Squelette Étudiant)	7
9.0.a 1. Préparation de l'environnement	7
9.0.b 2. Génération du jeu d'images synthétiques	7
9.0.c 3. Split d'évaluation (Entraînement / Validation)	8
9.0.d 4. Conception de l'architecture du CNN	8
9.0.e 5. Compilation et Entraînement	8
10 Évaluation Métrique et Validation	8
10.1 Stratégie de Validation Chronologique	8
10.2 Résultats et Interprétation	8
11 Data Storytelling et Communication	8
11.1 Recommandations pour la Métropole	8
11.2 Limites et Perspectives	9
Bibliographie	9
Bibliography	9

1 Introduction et Contexte Métier



Figure 1: CI Compilation Pipeline

À rédiger par les étudiants : Présentez ici le contexte global du projet de transition écologique de la métropole, les enjeux sociétaux de la mobilité active, les questions scientifiques soulevées et la problématique métier que vous cherchez à résoudre.

1.1 Contexte du Projet

À rédiger par les étudiants — Pistes de réflexion : - Quels sont les objectifs environnementaux globaux de la métropole en matière de réduction d'empreinte carbone et de pollution ? - En quoi la promotion de la mobilité active (vélo) et des transports en commun (bus) constitue-t-elle un levier d'action stratégique ? - Pourquoi l'analyse quantitative des données de trafic est-elle indispensable pour piloter les infrastructures urbaines ?

[Rédiger votre paragraphe de contexte ici]

1.2 Objectif Analytique

À rédiger par les étudiants — Pistes de réflexion : - Quelles sont les variables cibles principales (ex: bike_count) et la tâche prédictive globale ? - Comment le couplage de données physiques (météo, pollution, trafic) et d'images (brique de vision CNN) permet-il d'adopter une approche multi-sources ? - Quels sont les livrables analytiques attendus pour aider la métropole dans ses prises de décisions stratégiques ?

[Rédiger votre paragraphe d'objectifs ici]

2 Acquisition et Préparation des Données (Data Wrangling)

Le succès de tout projet de Data Science repose sur la qualité de la préparation des données [1]. Cette section documente l'audit de qualité et les étapes de nettoyage appliquées au jeu de données de capteurs brut.

2.1 Audit de Qualité

À rédiger par les étudiants : Présentez un audit critique complet du fichier de données brutes. Indiquez la liste des anomalies physiques et typologiques détectées (formats de dates, outliers physiques, taux de valeurs manquantes).

[Rédiger votre audit de données ici]

2.2 Algorithme de Nettoyage

À rédiger par les étudiants : Justifiez et détaillez l'enchaînement de vos opérations de traitement (uniformisation des dates, masquage des outliers physiques par NaN, imputation temporelle). Faites référence aux fonctions correspondantes de votre module `src/data_clean.py`.

[Rédiger la justification méthodologique ici]

2.3 Travaux Pratiques de Wrangling

3 Jalon 1 : Data Wrangling & Nettoyage (Squelette Étudiant)

Ce notebook correspond à la première étape du **Jalon 1**. L'objectif est d'importer le jeu de données brut (`data/raw/raw_data_sample.csv`), d'effectuer un audit de sa qualité (données manquantes, anomalies physiques, formats de dates hétérogènes) et de le nettoyer à l'aide de votre package personnalisé `src.data_clean`.

3.0.a 1. Importation des packages et chargement des données

3.0.b 2. Audit initial des données

À faire par l'étudiant : Explorez le dataset brut pour évaluer sa structure : - Quelles sont les dimensions du dataset ? - Quels sont les types de données par colonne ? - Reste-t-il des valeurs nulles ? Quel est le taux de valeurs manquantes par variable ? - Y a-t-il des doublons ?

3.0.c 3. Nettoyage et uniformisation des Dates

À faire par l'étudiant : Appliquez la fonction `clean_dates` de votre module `src.data_clean` pour convertir la colonne `timestamp` en type `Datetime` uniforme.

3.0.d 4. Identification et Traitement des Outliers (Anomalies physiques)

À faire par l'étudiant : Analysez les valeurs de la colonne `value` et appliquez votre fonction `handle_outliers` pour filtrer les valeurs physiques aberrantes (inférieures à 0 ou supérieures à 100).

3.0.e 5. Imputation des valeurs manquantes

À faire par l'étudiant : Appliquez la fonction `impute_missing_values` pour remplir les NaNs issus du chargement initial ou du nettoyage des anomalies.

3.0.f 6. Sauvegarde des données propres

Enregistrez votre DataFrame nettoyé dans `data/processed/cleaned_data_sample.csv`.

4 Analyse Exploratoire des Données (EDA)

Dans cette section, nous analysons les relations statistiques fondamentales qui régissent la mobilité active (vélos) et les transports en commun (bus) au sein de la métropole.

4.1 Statistiques Descriptives

À rédiger par les étudiants : Présentez une vue d'ensemble descriptive rapide de vos variables nettoyées.

[Rédiger les statistiques descriptives ici]

4.2 Ingénierie de Variables (Feature Engineering)

À rédiger par les étudiants : Expliquez l'intérêt mathématique et l'impact sur les modèles prédictifs d'extraire des composantes temporelles cycliques (comme l'encodage sinus / cosinus des heures).

[Rédiger votre explication de l'ingénierie de variables ici]

4.3 Travaux Pratiques d'Exploration Visuelle (EDA)

5 Jalon 1 : Analyse Exploratoire des Données (EDA) & Visualisation (Squelette Étudiant)

Ce notebook est dédié à la découverte de relations clés et à l'analyse visuelle de nos données. À partir du jeu de données propre généré précédemment, nous allons enrichir nos variables explicatives et appeler les fonctions de notre module de visualisation `src.utils_viz` pour générer des graphiques professionnels.

5.0.a 1. Importation des packages et configuration du style

5.0.b 2. Ingénierie de variables temporelles

À faire par l'étudiant : Appliquez la fonction `feature_engineering` de `src.data_clean` pour enrichir votre DataFrame en caractéristiques de temps classiques (heures, jours de la semaine).

5.0.c 3. Visualisations Professionnelles

5.0.c.a A. Profils d'évolution et tendances

À faire par l'étudiant : Appliquez la fonction `plot_generic_trends` de votre module `src.utils_viz` pour tracer l'évolution de la valeur par rapport au temps.

5.0.c.b B. Matrice de corrélation multi-variables

À faire par l'étudiant : Appliquez la fonction `plot_correlation_matrix` de votre module `src.utils_viz` pour calculer et afficher graphiquement la carte thermique des corrélations sur les colonnes `['value', 'hour', 'dayofweek']`.

5.0.c.c C. Nuage de points bivarié

À faire par l'étudiant : Générez un nuage de points de la relation heure vs valeur en colorant les points selon la variable `dayofweek`, en utilisant votre fonction `plot_bivariate_scatter`.

5.0.d 4. Synthèse des observations clés

Sur la base de vos figures, listez les **insights majeurs** observés sur le comportement de vos variables.

6 Visualisation Multidimensionnelle (Insights)

Nous présentons ici les résultats visuels clés permettant de dégager des insights exploitables pour les décideurs publics, en s'appuyant sur notre module `src/utils_viz.py`.

À rédiger par les étudiants : Présentez et commentez en détail vos 3 à 5 insights majeurs découverts lors de l'exploration descriptive visuelle. Intégrez et justifiez les figures clés générées.

6.1 Profils d'Activité Journalière

```
#| label: fig-traffic-density
#| fig-cap: "Profil horaire moyen des déplacements (Vélos vs Bus)."
```

#| echo: false

TODO: Utiliser `uv.plot_traffic_density()` de votre module pour tracer la figure

[Commenter la figure et décrire vos observations ici]

6.2 Corrélations Globales

```
#| label: fig-correlation
#| fig-cap: "Matrice de corrélation de Spearman entre variables."
```

```
#| echo: false
# TODO: Utiliser uv.plot_correlation_matrix() de votre module pour tracer la
figure
```

[Commenter la figure et décrire vos observations ici]

7 Modélisation et Apprentissage

7.1 Schéma Global du Pipeline de Données

Le pipeline complet intègre à la fois la branche analytique tabulaire (Machine Learning) et la branche d'analyse visuelle (Deep Learning CNN) :

```
graph TD
    A[Données Capteurs Brutes CSV] -->|Formatage & Alignement| B(data_clean.clean_dates)
    B --> C[Données Météo & Pollution]
    C -->|Imputation & Interpolation| D(data_clean.impute_missing_values)
    D --> B
    B & D -->|Gestion Outliers| E[Jeu de données Propre & Fusionné]
    E -->|Extraction Temporelle| F[Feature Engineering]
    F -->|Splits Temporels Chronologiques| G[Modèle Machine Learning Tabulaire]
    G --> H[Flux Caméras Trafic en Temps Réel]
    H -->|Prétraitement d'images 64x64| I[Réseau Convolutif CNN TensorFlow]
    I --> G
    G --> J[Livrables & Aide à la Décision Métropole]
    J --> I
    I --> K[Détection de Congestion]
    K --> J

    style E fill:#e0f2fe,stroke:#0284c7,stroke-width:2px
    style J fill:#f0fdf4,stroke:#16a34a,stroke-width:2px
    style G fill:#fef3c7,stroke:#d97706,stroke-width:2px
    style I fill:#fef3c7,stroke:#d97706,stroke-width:2px
```

7.2 Modélisation Tabulaire (Prédiction Vélos)

À rédiger par les étudiants : Expliquez le choix de votre algorithme d'apprentissage supervisé (Forêt Aléatoire) et décrivez l'importance des variables explicatives.

[Détaillez votre modélisation ici]

7.2.a Travaux Pratiques de Modélisation Tabulaire

8 🧠 Jalon 2 : Modélisation Prédicative & Apprentissage (Squelette Étudiant)

Dans ce notebook du **Jalon 2**, l'objectif est d'implémenter un pipeline complet d'apprentissage supervisé pour prédire une variable cible (value) à l'aide de Scikit-Learn.

Vous devrez mettre en œuvre une stratégie de découpage train/test chronologique pour respecter la causalité temporelle.

8.0.a 1. Préparation de l'environnement

8.0.b 2. Définition des variables et split chronologique

À faire par l'étudiant : - Identifiez vos colonnes prédictives (features) et la colonne cible (value). - Séparez chronologiquement vos données en ensembles d'entraînement (Train) et de test (Test). N'utilisez pas de split aléatoire !

8.0.c 3. Entraînement du modèle de Forêt Aléatoire

À faire par l'étudiant : - Instanciez et entraînez un modèle RandomForestRegressor. - Générez les prédictions `y_pred` sur l'ensemble de test.

8.0.d 4. Évaluation métrique

À faire par l'étudiant : Calculez et affichez les scores d'évaluation requis : - **MAE** (Mean Absolute Error) - **RMSE** (Root Mean Squared Error) - **R²** (Coefficient de détermination)

8.0.e 5. Importance des variables explicatives

À faire par l'étudiant : Extrayez et affichez l'importance relative de chaque caractéristique prédictive.

8.1 Modélisation Vision (Analyse d'Images)

À rédiger par les étudiants : Expliquez l'intérêt de la brique de Deep Learning d'images pour classifier le trafic. Détaillez l'architecture de votre réseau de neurones convolutif (CNN) conçu sous TensorFlow/Keras (conv, pooling, dense, dropout, activation) et commentez les courbes d'apprentissage obtenues.

[Détaillez votre architecture CNN et analysez ici]

8.1.a Travaux Pratiques de Vision par Ordinateur (CNN)

9 Jalon 2 : Brique de Vision par Ordinateur (CNN & TensorFlow) (Squelette Étudiant)

Ce notebook est dédié à la brique d'analyse d'images du **Jalon 2**. L'objectif est de concevoir un Réseau de Neurones Convolutif (CNN) sous TensorFlow/Keras pour classifier des motifs géométriques simples (Classe 0: Cercle vs Classe 1: Multiples Rectangles).

9.0.a 1. Préparation de l'environnement

9.0.b 2. Génération du jeu d'images synthétiques

Pour travailler de manière autonome sans importer de lourdes bases d'images externes, cette fonction utilitaire génère des images simulées en 64×64 pixels de formes simples (Cercle vs Rectangles).

9.0.c 3. Split d'évaluation (Entraînement / Validation)

À faire par l'étudiant : Divisez vos données d'images `x_images` et `y_labels` en 80% pour l'entraînement et 20% pour la validation.

9.0.d 4. Conception de l'architecture du CNN

À faire par l'étudiant : Instanciez un réseau convolutif séquentiel Keras comprenant des couches Conv2D, MaxPooling2D, Flatten, Dense et un Dropout pour classer nos deux formes géométriques.

9.0.e 5. Compilation et Entraînement

À faire par l'étudiant : - Compilez le modèle avec l'optimiseur 'adam' et la fonction de perte binaire. - Entraînez votre CNN sur environ 5 époques.

10 Évaluation Métrique et Validation

10.1 Stratégie de Validation Chronologique

À rédiger par les étudiants : Expliquez pourquoi un découpage d'évaluation aléatoire classique violerait le principe de causalité temporelle et comment vous avez configuré une validation temporelle rigoureuse.

[Rédiger la section de validation ici]

10.2 Résultats et Interprétation

À rédiger par les étudiants : Complétez le tableau d'évaluation ci-dessous en reportant vos résultats de modélisation.

Modèle	MAE (cyclistes)	RMSE (cyclistes)	R^2 (%)
Baseline Historique	[À compléter]	[À compléter]	[À compléter]
Forêt Aléatoire	[À compléter]	[À compléter]	[À compléter]

[Interpréter et comparer les métriques d'erreur calculées ici]

11 Data Storytelling et Communication

11.1 Recommandations pour la Métropole

À rédiger par les étudiants : Formulez des recommandations stratégiques, opérationnelles et innovantes pour aider les décideurs publics sur la base de vos découvertes analytiques et prédictives.

[Rédiger vos recommandations ici]

11.2 Limites et Perspectives

À rédiger par les étudiants : Identifiez honnêtement les biais ou limites de votre approche et proposez des pistes d'amélioration futures (ex: intégration de données externes réelles, modélisation plus poussée).

[Rédiger les limites et perspectives ici]

Ce document dynamique a été compilé en Quarto [2].

Bibliographie

Bibliography

- [1] W. McKinney, *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython*. O'Reilly Media, 2020.
- [2] Q. D. Team, “Quarto Dynamic Publishing System: Collaborative Scientific and Technical Publishing.” Accessed: May 18, 2026. [Online]. Available: <https://quarto.org/>