

Mon Projet Data Science

Projet Fil Rouge Data Science - Sujet Libre

2026-05-21

Table of contents

1	Introduction et Contexte Métier	2
1.1	Contexte du Projet	3
1.2	Objectif Analytique	3
2	Acquisition et Préparation des Données (Data Wrangling)	3
2.1	Chapitre 1 : Acquisition Multi-Sources	4
3	 Étape 1 : Acquisition des Données & Multi-Sources (Squelette Étudiant)	4
3.0.a	1. Initialisation de l'environnement	4
3.0.b	2. Chargement de la source de données principale	4
3.0.c	3. Intégration de données secondaires (Multi-Sources)	4
3.0.d	4. Fusion des sources (Optionnel)	4
3.0.e	5. Consignation des données d'entrée brutes	4
3.1	Chapitre 2 : Nettoyage et Préparation (Wrangling)	4
4	 Étape 2 : Préparation & Nettoyage de Données (Data Wrangling) (Squelette Étudiant) ...	4
4.0.a	1. Initialisation et imports	4
4.0.b	2. Chargement du dataset brut et Audit Initial	4
4.0.c	3. Uniformisation des Formats de Dates	4
4.0.d	4. Identification et Filtrage des Valeurs Aberrantes (Outliers)	5
4.0.e	5. Imputation des valeurs manquantes	5
4.0.f	6. Sauvegarde des données propres	5
5	Visualisation Multidimensionnelle (Insights)	5
5.1	Chapitre 3 : Travaux Pratiques d'Exploration Visuelle	5
6	 Étape 4 : Visualisation Multidimensionnelle (Squelette Étudiant)	5
6.0.a	1. Préparation de l'environnement	5
6.0.b	2. Chargement du dataset enrichi	5
6.0.c	3. Tracés et analyses graphiques	5
7	Analyse Exploratoire des Données (EDA)	6
7.1	Chapitre 4 : Travaux Pratiques d'Exploration (EDA)	6
8	 Étape 3 : Analyse Exploratoire des Données (EDA) (Squelette Étudiant)	6
8.0.a	1. Préparation de l'environnement	6
8.0.b	2. Chargement des données nettoyées	6
8.0.c	3. Statistiques Descriptives	6

8.0.d	4. Ingénierie de variables (Feature Engineering)	6
8.0.e	5. Analyse des Corrélations	6
9	Modélisation et Apprentissage	6
9.1	Chapitre 5 : Travaux Pratiques de Modélisation (ML & DL)	7
10	 Étape 5 : Modélisation (Machine Learning & Deep Learning)	7
10.1	1. Préparation de l'environnement	7
10.2	2. Modélisation Tabulaire (Machine Learning)	7
10.3	3. Modélisation Vision / Deep Learning (CNN & TensorFlow)	7
11	Évaluation Métrique et Validation	8
11.1	Chapitre 6 : Travaux Pratiques d'Évaluation & Robustesse	8
12	 Étape 6 : Évaluation Métrique & Robustesse	8
12.1	1. Préparation de l'environnement	8
12.2	2. Évaluation du modèle Tabulaire (RandomForest)	8
12.3	3. Validation croisée (K-Fold)	8
12.4	 Conclusion	8
13	Data Storytelling et Communication	9
13.1	Chapitre 7 : Travaux Pratiques de Storytelling	9
14	 Étape 7 : Data Storytelling & Communication	9
14.1	1. Préparation de l'environnement	9
14.2	2. Synthèse métier et Storytelling	9
14.2.a	 Insights majeurs	9
14.2.b	 Recommandations stratégiques	10
14.3	3. Visualisation Interactive (Plotly)	10
14.4	4. Dashboard interactif complet	10
14.4.a	 Lancement du dashboard	10
14.4.b	 Limites de l'étude	10
14.5	Présentation des Résultats (Livrables Interactifs)	11
14.5.a	 Diaporama de Soutenance (RevealJS)	11
14.5.b	 Exemple de Dashboard Dynamique (OJS / Plotly)	11
15	Utilisation de l'Intelligence Artificielle	12
15.1	Cartographie de l'utilisation de l'IA	12
15.2	Principes de Rigueur et Responsabilité	12
	Bibliographie	12
	Bibliography	13

1 Introduction et Contexte Métier

À rédiger par les étudiants : Présentez ici le contexte global de votre projet, la problématique métier que vous cherchez à résoudre, les questions scientifiques soulevées et les opportunités d'aide à la décision sur la base de vos données.

1.1 Contexte du Projet

À rédiger par les étudiants — Pistes de réflexion :

- *Quels sont les objectifs globaux et le domaine d'étude de votre projet ?*
- *En quoi ce sujet de recherche est-il pertinent et stratégique ?*
- *Pourquoi l'analyse quantitative de ce jeu de données est-elle indispensable pour répondre à votre problématique ?*

[Ce projet s'inscrit dans une problématique de Data Science appliquée au marché immobilier californien. À partir du dataset House Prices (Kaggle, 1 460 biens, 81 variables), nous analysons les facteurs qui influencent le prix de vente d'un bien immobilier et construisons un pipeline complet de Data Science combinant Machine Learning tabulaire et Deep Learning sur images.

L'analyse quantitative de ce jeu de données est indispensable car le marché immobilier est fortement hétérogène : les prix varient de manière complexe et non-linéaire selon des dizaines de critères (qualité de construction, surface, localisation, âge du bien). Seule une approche algorithmique permet de modéliser ces interactions et d'objectiver les facteurs déterminants du prix.]

1.2 Objectif Analytique

À rédiger par les étudiants — Pistes de réflexion :

- *Quelles sont les variables cibles principales et la tâche globale de modélisation (classification, régression, clustering, etc.) ?*
- *Comment le couplage de données multi-sources et l'intégration de différents types de données (tabulaires, images, signaux, etc.) enrichissent-ils l'analyse ?*
- *Quels sont les livrables analytiques attendus pour répondre à votre problématique et guider les prises de décisions ?*

[La variable cible principale est **SalePrice** (prix de vente en dollars) — il s'agit d'une tâche de **régression supervisée**.

Le projet combine deux types de données complémentaires : des données tabulaires structurées (caractéristiques physiques du bien) et des données non structurées (photographies réelles des maisons), constituant une approche **multimodale**.

Les livrables analytiques produits sont :

- Un modèle **Random Forest Regressor** atteignant $R^2=0.73$ (explique 73% de la variance des prix)
- Un **CNN TensorFlow** classifiant les biens en 3 catégories de prix avec 52.5% d'accuracy
- Un **dashboard interactif Plotly Dash** incluant un simulateur de prix en temps réel
- Un **rapport complet Quarto** documentant l'ensemble de la démarche scientifique]

2 Acquisition et Préparation des Données (Data Wrangling)

Le succès de tout projet de Data Science repose sur la qualité de la préparation des données [1]. Cette section documente l'audit de qualité et les étapes de nettoyage appliquées à vos jeux de données bruts.

2.1 Chapitre 1 : Acquisition Multi-Sources

3 📦 Étape 1 : Acquisition des Données & Multi-Sources (Squelette Étudiant)

Cette étape correspond au premier chapitre du pipeline de Data Science. L'objectif est d'identifier, d'importer et de consolider vos jeux de données bruts issus de différentes sources (fichiers CSV locaux, requêtes API, bases de données, etc.).

3.0.a 1. Initialisation de l'environnement

3.0.b 2. Chargement de la source de données principale

À COMPLÉTER PAR L'ÉTUDIANT : Chargez votre jeu de données principal (par exemple un fichier CSV stocké dans `data/raw/`).

3.0.c 3. Intégration de données secondaires (Multi-Sources)

À COMPLÉTER PAR L'ÉTUDIANT : Mettez en place la récupération de vos données complémentaires (par exemple, appels d'API fictifs ou réels, données météo, géographiques, ou financiers complémentaires).

3.0.d 4. Fusion des sources (Optionnel)

À COMPLÉTER PAR L'ÉTUDIANT : Associez vos différentes sources de données en utilisant des jointures (`pd.merge`) pertinentes.

3.0.e 5. Consignation des données d'entrée brutes

Sauvegardez l'état brut de vos données d'entrée pour la suite du pipeline.

3.1 Chapitre 2 : Nettoyage et Préparation (Wrangling)

4 🧹 Étape 2 : Préparation & Nettoyage de Données (Data Wrangling) (Squelette Étudiant)

Cette étape correspond au deuxième chapitre du projet. L'objectif est d'effectuer un audit de qualité de vos données brutes, puis de mettre en œuvre un nettoyage rigoureux à l'aide de votre package personnalisé `src.data_clean`.

4.0.a 1. Initialisation et imports

4.0.b 2. Chargement du dataset brut et Audit Initial

À COMPLÉTER PAR L'ÉTUDIANT : Chargez les données brutes et inspectez la qualité du dataset (taux de valeurs manquantes, présence de doublons, types erronés).

4.0.c 3. Uniformisation des Formats de Dates

À COMPLÉTER PAR L'ÉTUDIANT : Uniformisez la colonne temporelle pour la convertir dans un type datetime standardisé via votre module `src.data_clean`.

4.0.d 4. Identification et Filtrage des Valeurs Aberrantes (Outliers)

À COMPLÉTER PAR L'ÉTUDIANT : Identifiez les anomalies physiques et utilisez votre fonction `dc.handle_outliers` pour transformer ces valeurs aberrantes en NaNs.

4.0.e 5. Imputation des valeurs manquantes

À COMPLÉTER PAR L'ÉTUDIANT : Appliquez des stratégies d'imputation adaptées (interpolation temporelle, médiane, etc.) sur les valeurs manquantes générées ou initiales.

4.0.f 6. Sauvegarde des données propres

Enregistrez vos données de base nettoyées dans le répertoire `data/processed/`.

5 Visualisation Multidimensionnelle (Insights)

Nous présentons ici les résultats visuels clés permettant de dégager des insights exploitables pour les décideurs, en s'appuyant sur notre module `src/utils_viz.py`.

5.1 Chapitre 3 : Travaux Pratiques d'Exploration Visuelle

6 Étape 4 : Visualisation Multidimensionnelle (Squelette Étudiant)

Cette étape correspond au quatrième chapitre du cours. L'objectif est de concevoir des représentations visuelles premium pour identifier des tendances et insights clés à l'aide de votre package personnalisé de tracé `src.utils_viz`.

6.0.a 1. Préparation de l'environnement

6.0.b 2. Chargement du dataset enrichi

6.0.c 3. Tracés et analyses graphiques

6.0.c.a A. Évolution des tendances dans le temps

À COMPLÉTER PAR L'ÉTUDIANT : Tracez les tendances globales à l'aide de la fonction `uv.plot_generic_trends`.

6.0.c.b B. Carte de chaleur des corrélations

À COMPLÉTER PAR L'ÉTUDIANT : Visualisez graphiquement les corrélations de Pearson à l'aide de `uv.plot_correlation_matrix`.

6.0.c.c C. Nuage de points bivarié

À COMPLÉTER PAR L'ÉTUDIANT : Générez une analyse graphique bivariée en utilisant `uv.plot_bivariate_scatter`.

7 Analyse Exploratoire des Données (EDA)

Dans cette section, nous analysons les relations statistiques fondamentales qui régissent votre domaine d'étude au sein du jeu de données.

7.1 Chapitre 4 : Travaux Pratiques d'Exploration (EDA)

8 Étape 3 : Analyse Exploratoire des Données (EDA) (Squelette Étudiant)

Cette étape correspond au troisième chapitre du cours. L'objectif est d'explorer et de résumer les propriétés statistiques fondamentales de vos données et de réaliser du **Feature Engineering** pour enrichir vos modèles.

8.0.a 1. Préparation de l'environnement

8.0.b 2. Chargement des données nettoyées

8.0.c 3. Statistiques Descriptives

À COMPLÉTER PAR L'ÉTUDIANT : Générez les résumés statistiques globaux et par groupes/catégories de votre jeu de données.

8.0.d 4. Ingénierie de variables (Feature Engineering)

À COMPLÉTER PAR L'ÉTUDIANT : Appliquez la fonction `feature_engineering` de `src.data_clean` pour extraire des indicateurs temporels de base, et ajoutez d'autres variables dérivées complexes adaptées à votre problématique.

8.0.e 5. Analyse des Corrélations

À COMPLÉTER PAR L'ÉTUDIANT : Analysez la matrice des corrélations des caractéristiques numériques à l'aide de Pandas.

9 Modélisation et Apprentissage

Le pipeline complet intègre à la fois la branche analytique tabulaire (Machine Learning) et la branche d'analyse visuelle ou de signaux complexes (Deep Learning CNN) :

```
graph TD
    A[Données Brutes Multi-Sources CSV/API] -->|Formatage & Alignement| B(data_clean.clean_dates)
    C[Données Externes Complémentaires] -->|Imputation & Interpolation| D(data_clean.impute_missing_values)
    B & D -->|Gestion Outliers| E[Jeu de données Propre & Fusionné]
    E -->|Extraction Temporelle/Caractéristiques| F[Feature Engineering]
    F -->|Splits Temporels ou Stratifiés| G[Modèle Machine Learning Tabulaire]
    H[Flux Multimédias Réels Images/Signaux] -->|Prétraitement d'images/signaux|
```

```

I[Réseau Convolutif CNN TensorFlow]
G -->|Prédictions de la Problématique Métier| J[Livrables & Aide à la Décision]
I -->|Détection de Motifs Complexes| J

style E fill:#e0f2fe,stroke:#0284c7,stroke-width:2px
style J fill:#f0fdf4,stroke:#16a34a,stroke-width:2px
style G fill:#fef3c7,stroke:#d97706,stroke-width:2px
style I fill:#fef3c7,stroke:#d97706,stroke-width:2px

```

9.1 Chapitre 5 : Travaux Pratiques de Modélisation (ML & DL)

10 🧠 Étape 5 : Modélisation (Machine Learning & Deep Learning)

Cette étape correspond au cinquième chapitre du cours. L'objectif est d'implémenter d'une part un modèle de **Machine Learning tabulaire** (RandomForest) pour la prédiction du prix de vente, et d'autre part un **réseau de neurones convolutif (CNN)** sous TensorFlow pour classifier les biens immobiliers à partir de leurs photos.

10.1 1. Préparation de l'environnement

Importation des bibliothèques nécessaires pour la modélisation tabulaire (scikit-learn) et chargement du dataset nettoyé issu de l'étape de wrangling.

10.2 2. Modélisation Tabulaire (Machine Learning)

Nous entraînons un **Random Forest Regressor** pour prédire le prix de vente (**SalePrice**) à partir de six caractéristiques numériques sélectionnées lors de l'EDA pour leur forte corrélation avec la variable cible.

Features retenues : - **GrLivArea** — Surface habitable - **OverallQual** — Qualité globale du bien - **HouseAge** — Âge de la maison - **GarageCars** — Capacité du garage - **TotalBsmtSF** — Surface du sous-sol - **coef_multiplieur** — Coefficient de zone (Standard / Premium / Luxury)

10.3 3. Modélisation Vision / Deep Learning (CNN & TensorFlow)

Pour la brique Deep Learning, nous avons entraîné un **réseau de neurones convolutif (CNN)** sous TensorFlow pour classifier les biens immobiliers en trois catégories de prix (Économique, Moyenne, Luxe) à partir de photographies réelles.

Dataset utilisé : *House Prices and Images SoCal* (Kaggle) — 15 474 maisons californiennes avec photos.

Architecture du CNN : - 3 blocs convolutifs (32, 64, 128 filtres) + MaxPooling - Flatten + Dropout 30% - Dense 128 ReLU - Sortie Dense 3 neurones (softmax)

Résultats obtenus : - Accuracy test : **52.5%** (vs 33% pour le hasard pur) - Précision sur la classe **Luxe** : 67%

 **Note technique** : L'entraînement du CNN a été réalisé sur **Google Colab** (TensorFlow non installable en local Windows). Le code complet est disponible dans [src/06_cnn_house_styles.py](#). Le modèle entraîné et les prédictions sont versionnés dans `models/` et `data/processed/cnn_predictions.csv`.

11 Évaluation Métrique et Validation

11.1 Chapitre 6 : Travaux Pratiques d'Évaluation & Robustesse

12 Étape 6 : Évaluation Métrique & Robustesse

Cette étape correspond au sixième chapitre du cours. L'objectif est de mettre en place un **protocole d'évaluation rigoureux** et de calculer les métriques clés de performance pour valider scientifiquement la qualité de notre modèle de prédiction des prix immobiliers.

Nous appliquons : - Un **calcul détaillé des métriques d'erreur** (MAE, RMSE, R^2) - Une **validation croisée K-Fold** pour mesurer la robustesse du modèle

12.1 1. Préparation de l'environnement

Importation des bibliothèques d'évaluation et chargement du modèle entraîné lors de l'étape 5.

12.2 2. Évaluation du modèle Tabulaire (RandomForest)

Calcul des trois métriques de référence pour la régression : - **MAE** (Mean Absolute Error) — erreur moyenne en dollars - **RMSE** (Root Mean Squared Error) — pénalise davantage les grosses erreurs - **R^2** (Coefficient de détermination) — proportion de la variance expliquée par le modèle

12.3 3. Validation croisée (K-Fold)

Pour évaluer la **robustesse** du modèle au-delà d'un simple split train/test, nous appliquons une **validation croisée K-Fold** avec $K=5$.

Principe : le dataset est divisé en 5 sous-ensembles. Le modèle est entraîné et évalué 5 fois, en utilisant à chaque fois un sous-ensemble différent comme test. La moyenne des scores donne une estimation plus fiable de la performance réelle.

Pourquoi K-Fold classique et non TimeSeriesSplit ? Les données immobilières ne présentent pas de structure temporelle stricte (le prix d'une maison ne dépend pas de l'ordre dans lequel les ventes sont enregistrées dans le dataset). Une validation croisée classique est donc adaptée.

12.4 Conclusion

Le modèle RandomForest démontre une performance **robuste et reproductible** : - **R^2 test set** : **0.73** (mesure simple) - **R^2 5-Fold** : **0.75 ± 0.03** (validation croisée) - **Erreur moyenne (MAE)** : **~21 000 \$**

La très faible variance entre les folds (écart-type R^2 de 0.03) confirme que le modèle ne souffre pas de surapprentissage sur un sous-ensemble particulier des données. Les performances sont cohérentes quelle que soit la partition du dataset, ce qui valide scientifiquement l'utilisation de ce modèle pour la prédiction des prix immobiliers.

13 Data Storytelling et Communication

13.1 Chapitre 7 : Travaux Pratiques de Storytelling

14 📢 Étape 7 : Data Storytelling & Communication

Cette étape correspond au septième et dernier chapitre du cours. L'objectif est de synthétiser les résultats de notre pipeline de Data Science pour des profils métiers et de proposer une **restitution interactive** permettant aux décideurs d'explorer dynamiquement les insights.

14.1 1. Préparation de l'environnement

Importation des bibliothèques de visualisation interactive (Plotly) et chargement du dataset nettoyé.

14.2 2. Synthèse métier et Storytelling

Notre analyse du marché immobilier californien (1 460 biens) permet de dégager plusieurs **insights stratégiques** pour les agences, investisseurs et particuliers.

14.2.a 🗝️ Insights majeurs

1. **La qualité prime sur la surface** — Le facteur `OverallQual` représente **57%** de l'importance prédictive du modèle, soit **trois fois plus** que la surface habitable. Un acheteur soucieux de la valeur de revente devrait donc privilégier des biens de qualité de construction supérieure plutôt que des biens spacieux mais ordinaires.
2. **L'asymétrie du marché** — Le prix moyen (178 094 \$) est nettement supérieur au prix médian (163 000 \$), révélant une distribution asymétrique avec une longue queue de biens haut de gamme. Cela suggère que **le marché premium tire les statistiques globales vers le haut**, masquant la réalité de la majorité des transactions.
3. **L'âge a un impact limité mais réel** — Contrairement aux idées reçues, l'âge de la maison ne pèse que **7%** dans la prédiction. Les acheteurs surestiment souvent l'impact de l'année de construction par rapport à la qualité d'entretien.
4. **La classification visuelle est faisable** — Le CNN identifie correctement les biens de luxe avec **67% de précision** à partir d'une seule photo, démontrant qu'un système d'aide à la décision visuelle est techniquement viable.

14.2.b Recommandations stratégiques

Acteur	Recommandation
Agence immobilière	Mettre en avant la qualité de construction (OverallQual) dans les annonces — c'est le facteur d'achat n°1
Investisseur	Cibler les biens de qualité 7-8 dans les zones Standard : meilleur rapport qualité/prix selon le modèle
Particulier acheteur	Ne pas surpondérer l'âge du bien : privilégier la qualité de finition et la surface habitable
Promoteur	Investir dans la finition haut de gamme plutôt que dans la surface brute : ROI supérieur démontré

14.3 3. Visualisation Interactive (Plotly)

Génération d'un graphique interactif permettant aux décideurs d'explorer dynamiquement la relation entre les caractéristiques du bien et son prix.

14.4 4. Dashboard interactif complet

Pour une **expérience utilisateur complète**, un dashboard Plotly Dash a été développé. Il regroupe :

- **Section 1** — KPIs principaux du marché
- **Section 2** — Analyse exploratoire interactive (distributions, corrélations, boxplots)
- **Section 3** — **Simulateur de prix en temps réel** : l'utilisateur ajuste les caractéristiques d'un bien et obtient une estimation instantanée basée sur le modèle RandomForest

14.4.a Lancement du dashboard

```
py -3.13 src/08_dashboard.py
```

Puis ouvrir dans le navigateur : <http://127.0.0.1:8050>

14.4.b Limites de l'étude

- **Plafonnement des prédictions** vers 250 000 \$: la distribution du dataset ne couvre pas suffisamment les biens haut de gamme
- **Coefficient de zone peu discriminant** (0.8% d'importance) : la granularité géographique (3 classes) est insuffisante
- **CNN limité par le volume** : 1 000 images d'entraînement seulement, transfer learning ou data augmentation à explorer

14.5 Présentation des Résultats (Livrables Interactifs)

14.5.a Diaporama de Soutenance (RevealJS)

Ci-dessous est intégré le squelette de votre diaporama de soutenance RevealJS. Utilisez-le pour présenter votre démarche aux décideurs de façon professionnelle.

14.5.b Exemple de Dashboard Dynamique (OJS / Plotly)

Voici un exemple minimal de code montrant comment intégrer un graphique dynamique contrôlé par un composant d'interface utilisateur en Observable JS (OJS).

```
//| echo: true
// Boutons de sélection interactifs OJS
viewof selectedCategory = Inputs.select(["Toutes", "A", "B", "C"], {value:
"Toutes", label: "Filtrer par Catégorie :"})
```

```
//| echo: false
// Données simulées réactives
data = [
  {timestamp: "2026-05-18T00:00:00Z", value: 10.5, category: "A"},
  {timestamp: "2026-05-18T02:00:00Z", value: 12.1, category: "A"},
  {timestamp: "2026-05-18T04:00:00Z", value: 14.7, category: "A"},
  {timestamp: "2026-05-18T05:00:00Z", value: 15.2, category: "A"},
  {timestamp: "2026-05-18T06:00:00Z", value: 16.0, category: "B"},
  {timestamp: "2026-05-18T07:00:00Z", value: 18.3, category: "B"},
  {timestamp: "2026-05-18T09:00:00Z", value: 21.5, category: "B"},
  {timestamp: "2026-05-18T10:00:00Z", value: 22.0, category: "B"},
  {timestamp: "2026-05-18T12:00:00Z", value: 25.4, category: "C"},
  {timestamp: "2026-05-18T13:00:00Z", value: 26.1, category: "C"},
  {timestamp: "2026-05-18T15:00:00Z", value: 28.9, category: "C"},
  {timestamp: "2026-05-18T16:00:00Z", value: 30.2, category: "C"}
]
```

```
// Filtrage réactif de la donnée
filteredData = selectedCategory === "Toutes"
? data
: data.filter(d => d.category === selectedCategory)
```

```
// Tracé interactif avec la librairie Plotly
Plotly.newPlot('dynamic-chart', [{
  x: filteredData.map(d => d.timestamp),
  y: filteredData.map(d => d.value),
  type: 'scatter',
  mode: 'lines+markers',
```

```

marker: {color: '#1A73E8', size: 8},
line: {shape: 'spline', color: '#1A73E8', width: 3}
}], {
  title: 'Évolution Dynamique des Valeurs (Filtrée)',
  margin: {t: 50, b: 50, l: 50, r: 50},
  paper_bgcolor: 'rgba(0,0,0,0)',
  plot_bgcolor: 'rgba(0,0,0,0)',
  xaxis: {gridcolor: '#E5E7EB'},
  yaxis: {gridcolor: '#E5E7EB'}
})

```

15 Utilisation de l'Intelligence Artificielle

Dans une démarche de transparence scientifique et académique, cette section détaille la manière dont les outils d'Intelligence Artificielle (IA) générative ont été intégrés tout au long de la réalisation de ce projet.

15.1 Cartographie de l'utilisation de l'IA

Outil d'IA	Cas d'usage (Pourquoi ?)	Méthode d'utilisation (Comment ?)	Rôle et Validation Humaine
Claude (Anthropic)	Assistance au débogage du code et structuration du rapport	Outil de pair-programming utilisé pour débloquer des erreurs techniques et structurer les explications	Tous les choix techniques, algorithmes et analyses ont été décidés et validés par l'équipe ; le code a systématiquement été testé et compris avant intégration

15.2 Principes de Rigueur et Responsabilité

1. **Responsabilité intellectuelle** : L'équipe assume l'entière responsabilité des analyses, des choix de modèles et des conclusions présentées dans ce rapport.
 2. **Lutte contre les hallucinations** : Chaque suggestion technique a fait l'objet d'une validation empirique.
 3. **Protection des données** : Aucun jeu de données confidentiel ou sensible n'a été soumis à des modèles tiers en ligne.
-

Bibliographie

Bibliography

- [1] W. McKinney, *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython*. O'Reilly Media, 2020.